FAKULTA
APLIKOVANÝCH VĚD
ZÁPADOČESKÉ
UNIVERZITY
V PLZNI

Semestrální práce KIV/UIR

Klasifikace dokumentů

Pavel Třeštík
A17B0380P

21. května 2020

Obsah

1 Zadání

Ve zvoleném programovacím jazyce navrhněte a implementujte program, který umožní klasifikovat textové dokumenty do tříd podle jejich obsahu, např. počasí, sport, politika, apod. Při řešení budou splněny následující podmínky:

- Použijte data z českého historického periodika Posel od Čerchova“, která jsou k dispozici na `https://drive.google.com/drive/folders/1mQbBNS43gWFRMHDYdSkQug47cuhPTsHJ?usp=sharing`. V původní podobě jsou data k dispozici na `http://www.portafontium.eu/periodical/posel-od-cerchova-1872?language=cs`.
- Pro vyhodnocení přesnosti implementovaných algoritmů bude NUTNÉ vybrané dokumenty ručně označkovat. Každý student ručně anotuje 10 stran zadaného te xtu – termín 31.3.2020. Za dodržení termínu obdrží student bonus 10b.
- Přiřazení konkrétních textů jednotlivým studentům spolu s návodem na anotaci a příklady je uloženo spolu s daty na výše uvedené adrese, konkrétně:
  - 0 - vzorová složka (takhle by měl výsledek vypadat)
  - 1, 2, .. , 15, 101, 102, .. - data k anotaci
  - přiřazení souboru studentum.xlsx - určení, jaké soubory má jaký student anotovat. Až budete mít anotaci hotovou, doplňte sem informaci.
  - Anotační příručka - návod, jak články anotovat.
  - Klasifikace dokumentů - kategorie.xlsx - seznam kategorií k anotaci s příklady.
  - sem prace20.pdf - Zadání semestrální práce
- implementujte alespoň tři různé algoritmy (z přednášek i vlastní) pro tvorbu příznaků reprezentující textový dokument.
- implementujte alespoň dva různé klasifikační algoritmy (klasifikace s učitelem):
  - Naivní Bayesův klasifikátor

– klasifikátor dle vlastní volby

- funkčnost programu bude následující: – spuštění s parametry:
  název klasifikátoru, soubor se seznamem klasifikačních tříd, trénovací množina, testovací množina, parametrizační algoritmus, klasifikační algorit mus,název modelu
  program natrénuje klasifikátor na dané trénovací množině, použije zadaný parametrizační a klasifikační algoritmus, zároveň vyhodnotí úspěšnost klasifika ce a natrénovaný model uloží do souboru pro pozdější použití (např. s GUI).– spuštění s jedním parametrem:
  název klasifikátoru, název modelu
  program se spustí s jednoduchým GUI a uloženým klasifikačním modelem. Program umožní klasifikovat dokumenty napsané v GUI pomocí klávesnice (resp. překopí rované ze schránky).

- ohodnoťte kvalitu klasifikátoru na dodaných datech, použijte metriku přesnost (accuracy), kde jako správnou klasifikaci uvažujte takovou, kde se kla sifikovaná třída nachází mezi anotovanými. Otestujte všechny konfigurace klasifikátorů (tedy celkem 6 výsledků).

Poznámky:

- pro vlastní implementaci není potřeba čekat na dokončení anotace. Pro průběžné testování můžete použít korpus současné češtiny, který je k dispozici na `http://ctdc.kiv.zcu.cz/` (uvažujte pouze první třídu dokumentu podle názvu, tedy např. dokument 05857 zdr ptr eur.txt náleží do třídy zdr“ - zdravotnictví). ”

- další informace, např. dokumentace nebo forma odevzdávání jsou k dispozici na CW pod záložkou Samostatná práce.

2 Analýza úlohy

2.1 Algoritmy pro tvorbu příznaků

Existuje řada metod získávání informací (modelů) z rozdílných typů dat. Pro tuto práci nás ale zajímají pouze jazykové pravděpodobnostní modely. Ty se řadí do několika tříd: unigram, n-gram, exponenciální, neuronové sítě a ostatní (takové, které nepřipadají do ani jedné z předchozích skupin).
Ve skutečnosti ale některé třídy jsou založeny na jiné třídě. Na příklad unigram je ve skutečnosti n-gram pro jednotlivá slova. Mezi nejvýznačnější reprezentanty patří `Bag of Words`, `Bigram`, `Trigram` a `Word2vec`.

2.1.1 Bag of Words

Prvním z algoritmů, které jsem vybral je `Bag of Words`. Jedná se o unigram, tudíž každý text/ dokument je reprezentován jednotlivými slovy. Slova jsou ukládána do slovníku a jednotlivé klasifikační třídy/ dokumenty jsou reprezentovány vektory o délce slovníku. Hodnoty vektorů jsou reprezentací četností výskytu slov v textu/ dokumentu pro každou klasifikační třídu (nebo jednotlivé dokumenty). Toto ovšem vytváří problém, kdy při objemné množině slov ve slovníku, se jich pouze malá část vyskytuje ve vektoru reprezentující klasifikační třídu/ dokument.

Příklad `Bag of Words`
Zdroj (Wikipedia): `https://en.wikipedia.org/wiki/Bag-of-words_model`

Texty

```
(1) John likes to watch movies. Mary likes movies too.
(2) Mary also likes to watch football games.
```

Rozdělení textů

```
BoW1 = {"John":1,"likes":2,"to":1,"watch":1,"movies":2,"Mary":1,
"too":1};
BoW2 = {"Mary":1,"also":1,"likes":1,"to":1,"watch":1,"football":1,
"games":1};
```

Slovník textů

```
BoW3 = {"John":1,"likes":3,"to":2,"watch":2,
"movies":2,"Mary":2,"too":1,"also":1,"football":1,"games":1};
```

Vektory reprezentující texty
`(1) [1, 2, 1, 1, 2, 1, 1, 0, 0, 0]`
`(2) [0, 1, 1, 1, 0, 1, 0, 1, 1, 1]`

2.1.2 Bigram

Druhým algoritmem pro tvorbu příznaků bude `Bigram`. Ačkoliv `Bag of Words` je ve skutečnosti n-gram pro n = 1 a `Bigram` je n-gram pro n = 2 je v těchto algoritmech značný rozdíl. `Bigram` páruje slova a počítá pravděpodobnost páru jako podmíněnou pravděpodobnost obou slov páru.

Pravděpodobnost výrazu je spočítána podle vztahu na Obrázku 1. Párování slov je ukázáno na následujícím příkladu.

Věta
`Tato věta je příklad.`

Bigramy
`bigrams = {"S, Tato", "Tato, věta", "věta, je", "je, příklad", "příklad, /S}`

S = začátek věty, /S = konec věty

$$P(W_n|W_{n-1}) = \frac{P(W_{n-1}, W_n)}{P(W_{n-1})}$$

Obrázek 1: Pravděpodobnost výrazu bigramu
Zdroj: `https://en.wikipedia.org/wiki/Bigram`

2.1.3 TF-IDF

Posledním vybraným algoritmem je TF-IDF. Na rozdíl od předchozích dvou vybraných algoritmů nevytváří příznaky z textu, ale upravuje již existující příznaky, tudíž je využíván spolu s `Bag of Words`. Algoritmus ohodnotí jednotlivá slova váhou místo jejich četností. Čím častěji se slovo v textech/ dokumentech vyskytuje, tím nižší váhu má po TF-IDF. Tento algoritmus

svým způsobem "vytváří"takzvané **stop words**. To jsou slova, které v jazyce pro klasifikaci nemají žádný význam (na příklad pro Český jazyk slova jako: a, pro, nebo...).

2.2 Klasifikační algoritmy

Výběr klasifikačního algoritmu značně závisí na účelu našeho projektu. Z mnoha klasifikátorů jako je `Naive Bayes`, `Support Vector Machine (SVM)`, `Linear regression`, `Neural Networks` a dalších, potřebujeme vybrat podle potřeb. Nejdůležitějšími vlastnostmi klasifikátoru při výběru jsou jeho přesnost (accuracy), složitost a rychlost.

2.2.1 Naive Bayes

Je jeden z nejrychlejších a a nejjednodušších klasifikátorů. Jeho nedostatkem je, že potřebuje poměrně přesná trénovací data, aby jeho klasifikace byly co možná nejpřesnější.

Klasifikátor vybere nejpravděpodobnější třídu podle následujícího vztahu (viz Obrázek 2).

$$\hat{y} = \underset{k \in \{1,\ldots,K\}}{\operatorname{argmax}}\, p(C_k) \prod_{i=1}^{n} p(x_i \mid C_k).$$

Obrázek 2: Rovnice vybrání třídy
Zdroj: `https://en.wikipedia.org/wiki/Naive_Bayes_classifier`

2.2.2 k-nearest neighbors

Převede klasifikovaný text/ dokument na vektor a spočítá vzdálenost ke každému trénovacímu textu/ dokumentu. Poté přiřadí klasifikovanému textu třídu, která má nejvíce zástupců v určité blízkosti. Tento algoritmus je velmi jednoduchý a poměrně rychlý. Nevýhodou je přesnost, která pokud trénovací soubory nemají jednoznačně určenou třídu, není velmi vysoká.

Příklad klasifikace: zelená tečka na Obrázku 3. Zelená tečka bude klasifikována jako červený trojúhelník, protože v okolí jsou 2 červené trojúhelníky a pouze 1 modrý čtverec.

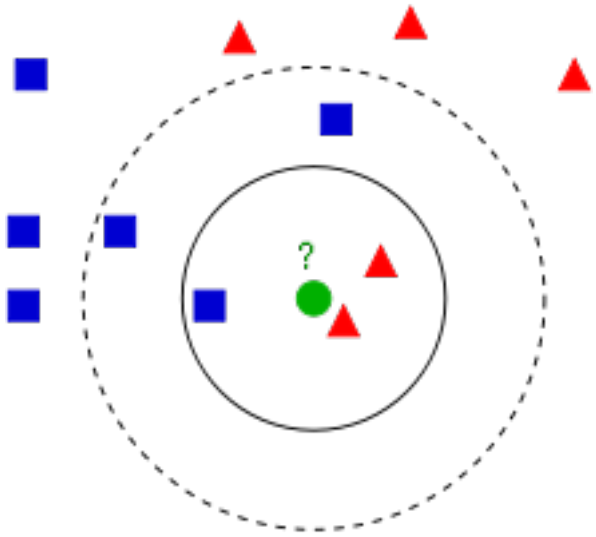

Obrázek 3: Příklad klasifikace k-nn
Zdroj:
`https://en.wikipedia.org/wiki/K-nearest_neighbors_algorithm`

3 Implementace

Pro tento projekt jsem zvolil jazyk Python. Důvodem bylo, že pro umělou inteligenci je pro Python množství knihoven. Naneštěstí jsem se k využití žádné z knihoven nedostal.

3.1 Bag of Words

Původně jsem tento model implementoval použitím teoretického způsobu. Neboli vytvořil jsem slovník a podle toho reprezentoval třídy jako vektory. Toto ale trvalo přibližně 15 vteřin.

Nakonec jsem začal jednotlivé třídy reprezentovat pomocí Python struktury **dictionary**. Tato struktura proces proces vytváření vektorů tříd urychlila na méně než vteřinu, ale není třeba dodržovat původní model a slovník není vůbec potřeba. Výhoda absence slovníku je, že každá třída nemá značné množství nul za slova, která se ve třídě nevyskytují.

3.2 Bigram

Také reprezentován pomocí struktury **dictionary**. Vytvářen velmi podobně jako `Bag of Words`, ale klíče slovníku jsou 2 slova oddělená mezerou.

Má změna o proti teoretickému způsobu algoritmu je v počítání pravděpodobnosti. Stejně jako u `Bag of Words`, jsou počítány pouze četnosti jednotlivých bigramů v textu. Pravděpodobnost je potom v klasifikátoru počítána jako `počet četností/ počet bigramů ve třídě`, což není správný způsob počítání pravděpodobnosti bigramu.

3.3 TF-IDF

Provádí výpočty přesně jak má. Implementován tak, aby počítal nad strukturou **dictionary**.

Navíc jsem se pokusil algoritmus doplnit o "normalizaci", se kterou lehce zvýší přesnost na poskytnutých datech.

Je možné použít originální i mou "normalizovanou"metodu, ale musí se přepnout ve zdrojovém kódu.

3.4 Naive Bayes

Implementován pro práci nad strukturou **dictionary**. Z důvodu velkého počtu slov ve třídách, čímž vznikaly pravděpodobnosti s příliš mnoho desetinnými místy pracuje v logaritmovaném prostoru. Místo násobení pravděpodobností, sčítá logaritmy pravděpodobností. Také používá tak zvaný **Laplace smoothing**, díky čemuž i slova, která se ve třídě nevyskytují mají malý vliv na klasifikaci místo nulového.

3.5 k-nearest neighbors

Pro tento algoritmus bylo třeba upravit příznakové metody, aby místo s jedním slovníkem definujícím třídu, vytvářely list souborů definující danou třídu.

Díky této úpravě může algoritmus fungovat přesně jak je popsán v analýze úlohy.

4 Uživatelská dokumentace

Program se spouští z konzole. Program je spustitelný na verzi Python 2.x. Program má Console mód a GUI mód. Console mód natrénuje klasifikátor a klasifikuje testovací množinu. GUI mód otevře jednoduché GUI okno kam uživatel vloží text, který chce klasifikovat. Aby se rozlišilo jestli se program spouští v příkazové řádce nebo v GUI má 2 rozdílné zpracování argumentů. Proto je nutno specifikovat, který použít, formou argumentu.

4.1 Konzolový mód

Program se spustí následujícím způsobem: **python main.py Console [-h] classes_name_file train_files test_files irs classifier model_name**

- **Console** – argument specifikující, které zpracování argumentů použít.
- **[-h]** – dobrovolný argument, při jehož použití se vypíše nápověda k ostatním argumentům.
- **classes_name_file** – soubor s listem klasifikovaných tříd. Jeden popisek třídy na každé řádce.
- **train_files** – adresář obsahující soubory, ze kterých se vytvoří model klasifikátoru.
- **test_files** – adresář obsahující soubory na kterých se otestuje model klasifikátoru.
- **irs** – způsob vytváření příznaků:
  - **bow** – použije `Bag of Words`
  - **bi** – použije `Bigram`
  - **bowtfidf** – použije `Bag of Words + TF-IDF`
- **classifier** – který klasifikátor se použije s modelem:
  - **nb** – použije `Naive Bayes`
  - **knn** – použije `k-nearest neighbors`
- **model_name** – název souboru, do kterého se model uloží.

4.2 GUI mód

Spuštění: **python main.py GUI [-h] model_name**

- **GUI** – argument specifikující, které zpracování argumentů použít.
- **[-h]** – dobrovolný argument, při jehož použití se vypíše nápověda k ostatním argumentům.
- **model_name** – název souboru, ze kterého se načte model, který se použije pro klasifikaci textu v grafickém rozhraní.

5 Shrnutí výsledků

Všechny kombinace jsou zahrnuty v následující tabulce (viz Tabulka 1).

Příznaková metoda	Klasifikátor	Přesnost
BoW	Naive Bayes	23.81%
Bigram	Naive Bayes	15.24%
Bow + TF-IDF	Naive Bayes	24.76%
BoW	k-nn	11.43%
Bigram	k-nn	12.38%
Bow + TF-IDF	k-nn	9.52%

Tabulka 1: Tabulka výsledků

První věcí, která je z výsledků zřejmá, je že žádná přesnost nedosahuje ani 30%. Původně jsem očekával výsledky mezi 30% až 60%. Bohužel těchto výsledků se nepodařilo dosáhnout. Hlavním důvodem proč jsou výsledky takto nepříznivě je pravděpodobně velká variace slov a fakt, že v programu nejsou použity žádné **stop words**.

Přesnost by se měla dát zvýšit přidáním **stop words**. Dalším způsobem zvýšení přesnosti by bylo ošetřit variaci slov. Slova z testovacích i trénovacích dat mají díky tomu, že jsou skenována OCR, velké množství chyb. To by se dalo částečně vylepšit používáním pouze kořenů slov (tak zvaný **stemming**). Druhým způsobem by bylo použít **word2vec**, který ze slov udělá vektory a dovolil by shlukovat vektory, které jsou si podobné.

6 Závěr

Program bohužel nedává moc dobré výsledky a nepodařilo se úplně naplnit mé představy. Myslím si, že by program mohl dosáhnout lepších výsledků, při použití některé z metod popsaných v předchozí sekci.

Dále by se program dal vylepšit úpravou implementací některých algoritmů.